

Universidad del Valle de Guatemala

Facultad de Ingenieria - Departamento de Ciencias de la Computacion

Laboratorio 6 - Análisis de redes sociales: YouTube

INFORME DE AVANCE: ACTIVIDADES 1 A 4

Autor: Daniel Adolfo Sarmiento Peralta

CC3084 - Data Science

Semestre II - 2026

Este informe fue generado de forma reproducible a partir de los dos archivos CSV proporcionados. Todas las tablas y figuras se reconstruyen ejecutando python run.py.

Resumen ejecutivo

Se analizaron 293 videos pertenecientes a 97 canales y 406 comentarios publicados por 332 autores únicos. Los 406 comentarios (100.0 %) pudieron asociarse con un registro de video mediante video_id. La participación observada esta fuertemente concentrada: el video con mas comentarios reúne 39.7 % y los cinco primeros reúnen 75.4 %.

La red bipartita contiene 332 autores, 19 videos y 343 pares autor-video distintos. Cada arista representa exclusivamente que un autor publicó uno o mas comentarios principales en un video; no demuestra amistad, respuesta directa, acuerdo ni aprobacion.

metrica	valor
Videos	293
Canales de videos	97
Comentarios	406
Autores de comentarios	332
Videos con comentarios recolectados	19
Canales con comentarios recolectados	8
Comentarios asociados a video	406
Me gusta acumulados en comentarios	2,325
Respuestas acumuladas	51

1. Carga, comprensión e integración de los datos

1.1 y 1.2. Unidad de observación, llaves y variables

archivo	unidad	llave primaria	variables relevantes
youtube_videos.csv	Un video	video_id	channel_id, title, view_count, publish_date, category, source_query, keywords, description
youtube_comments.csv	Un comentario principal	comment_id	video_id, author_channel_id, text, like_count_text, reply_count, source_query

Los nombres y handles se conservan como atributos descriptivos. No reemplazan los identificadores estables. En particular, `channel_name` identifica visualmente al propietario del video, mientras `author_name` identifica visualmente al autor del comentario.

1.3. Relación entre entidades

- Canal-video: un `channel_id` puede publicar varios videos; cada video pertenece al `channel_id` registrado.
- Video-comentario: `video_id` actúa como llave primaria en videos y llave foránea en comentarios.
- Autor-comentario: `author_channel_id` identifica la cuenta que publicó el comentario; no es el `channel_id` del canal comentado.
- Categoria: `category` describe la categoría asignada al video y se hereda a los comentarios solo mediante la unión con `video_id`.
- Consulta: `source_query` y `source_group` describen el procedimiento de muestreo, no una clasificación temática definitiva.

1.4. Integración

Se aplicó una unión muchos-a-uno desde comentarios hacia videos usando `video_id` y se validó que `video_id` fuera único en la tabla de videos. Resultado: 406 de 406 comentarios asociados; quedaron 0 sin coincidencia.

2. Calidad, limpieza y preprocesamiento

2.1. Diagnostico inicial

dataset	filas	columnas	llave_primaria	duplicados_llave	celdas_faltantes	variables_constantes
youtube_videos	293	20	video_id	0	77	Ninguna
youtube_comments	406	17	comment_id	0	406	is_pinned, viewer_rating

Las llaves primarias no presentan duplicados. viewer_rating esta vacia en los 406 comentarios e is_pinned es constante False. Las visualizaciones son muy asimetricas: la mediana es 1,175, frente a un máximo de 8,190,449; por eso los valores altos se tratan como observaciones validas potencialmente influyentes y no se eliminan automáticamente.

Faltantes y blancos relevantes

dataset	variable	faltantes_na	blancos_texto	porcentaje_afectado
youtube_comments	viewer_rating	406	0	100.000
youtube_comments	like_count_text	0	189	46.550
youtube_videos	description	26	0	8.870
youtube_videos	description_snippet	25	0	8.530
youtube_videos	published_time	13	0	4.440
youtube_videos	view_count_text	13	0	4.440

Consistencia de identificadores

comprobacion	casos
video_id duplicado en videos	0
comment_id duplicado	0
channel_id con varios nombres en videos	0
author_channel_id con varios nombres	0
upload_date distinto de publish_date	0
owner_handle distinto de channel_handle	0

2.2. Variables delicadas

- viewer_rating se excluye del análisis porque no tiene valores; is_pinned se conserva para auditoría pero no discrimina registros.
- published_time y published_text son tiempos relativos al momento de recolección; no se convierten en fechas exactas.
- view_count_text y like_count_text requieren limpieza. Para visualizaciones se usa view_count, ya numerica; los blancos de like_count_text se interpretan como cero visible y se documentan.
- source_query y source_group describen cobertura de búsqueda. No se interpretan automáticamente como tema real.
- reply_count indica cantidad de respuestas, pero no contiene identidad de quienes respondieron; nunca se usa para crear aristas entre usuarios.
- Los conteos son fotografías del momento de recolección y no son directamente comparables sin considerar antigüedad y cobertura.

2.3 y 2.4. Normalizacion y conteos

Los identificadores se normalizaron con Unicode NFKC y recorte de espacios, manteniendo video_id, comment_id, channel_id y author_channel_id. Los nombres se limpiaron solo para presentacion. El conversor numérico reconoce separadores y sufijos K, M, B, mil y millones; conserva una bandera de validez. En like_count_text, los espacios en blanco se transformaron a cero porque representan ausencia de un conteo visible, no un valor de popularidad desconocido.

2.5 a 2.7. Limpieza de texto

texto_original conserva el comentario exacto para auditoría. texto_limpio usa minúsculas, elimina URL y menciones, separa el contenido de hashtags, elimina puntuación, numeros, emojis y simbolos, y remueve stopwords en español. Se conservaron tildes y la letra ñ. No se aplico lematización: un modelo lingüístico externo introduciría una descarga y una version adicional; para este avance se priorizo reproducibilidad local y se documenta la decision.

metrica	valor
Registros originales	406
Registros eliminados	0
Textos modificados	403
Textos vacios antes	0
Textos vacios despues	6
Textos duplicados antes	2
Textos duplicados despues	11
Conteos like no validos	0

3. Análisis exploratorio

3.1. Participacion, popularidad y contenido




Figura 1. Comentarios recolectados por canal. La cobertura de comentarios se concentra en ocho canales.




Figura 2. Videos con mayor número de comentarios observados.

El video con mayor participación es 'Qué rico come tu diputado' del canal Quorum, con 161 comentarios y 128 autores únicos. El canal con mayor participación es Quorum, con 256 comentarios (63.1 % del total).




Figura 3. Distribuciones de visualizaciones, me gusta y respuestas. La asimetria obliga a interpretar medias y correlaciones con cautela.




Figura 4. Frecuencias de palabras y bigramas en texto_limpio; complementan, pero no sustituyen, el contexto cualitativo.

La palabra mas frecuente es 'pueblo' (56) y el bigrama principal es 'presidente bernardo' (9). El hashtag mas frecuente es #guatemala (48 apariciones). Las tablas completas se encuentran en resultados/tablas.




Figura 5. Categorías de los videos y clasificación preliminar de sentimiento.

El análisis preliminar basado en lexico clasifica 69.0 % como neutral, 21.7 % como positivo y 9.4 % como negativo. Es una aproximacion transparente y reproducible, pero no resuelve negacion, ironia, contexto ni variacion dialectal; no reemplaza el modelo final solicitado en la actividad 9.

3.2. Concentración de la participación




Figura 6. Curvas acumuladas de concentración. Una curva por encima de la diagonal indica que pocas unidades acumulan gran parte de los comentarios.

El primer video concentra 39.7 % de los comentarios; los cinco primeros, 75.4 %; y los diez primeros, 93.6 %. Por canal, el primero concentra 63.1 % y los cinco primeros, 96.1 %. Esta concentración describe la muestra y también refleja el procedimiento de recolección.

3.3. Visualizaciones y comentarios




Figura 7. Relación entre visualizaciones publicas y comentarios presentes en el archivo entregado.

Para los 293 videos, la correlación de Pearson entre visualizaciones y comentarios observados es -0.008, y Spearman es 0.080. Si se restringe a los 19 videos con comentarios recolectados, Pearson es 0.067 y Spearman es 0.811. Estas asociaciones no miden la tasa real de comentar: el archivo de comentarios cubre solo una selección de videos y posiblemente no contiene todos los comentarios existentes.

3.5. Respuestas a las preguntas obligatorias

- Videos y canales con mayor participación: lidera 'Qué rico come tu diputado' y el canal Quorum. Los rankings completos se entregan en `eda_videos.csv` y `eda_canales.csv`.
- Audiencias compartidas: 9 autores comentaron en mas de un video y 4 lo hicieron en mas de un canal. Se detectaron 11 pares de videos con al menos un autor compartido.
- Posibles puentes: se consideran candidatos preliminares los autores con mayor cantidad de `videos_unicos` y `canales_unicos`. Esta es recurrencia observada, no centralidad de intermediación; el cálculo formal corresponde a actividades posteriores.
- Temas y sentimiento: los términos dominantes incluyen 'pueblo' y 'presidente bernardo'. Los componentes conexos preliminares se caracterizan en `eda_componentes_preliminares.csv`; el sentimiento por lexico es mayoritariamente neutral.
- Visibilidad y participación: no coinciden necesariamente. La correlación sobre videos comentados es Spearman=0.811, y varios videos con muchas vistas carecen de comentarios en el archivo por cobertura, no necesariamente por ausencia de participación real.
- Limitaciones de cobertura: selección por consultas y canales, solo comentarios principales recuperados, fechas relativas, conteos observados en un momento, falta de relaciones autor-respuesta y fuerte concentración en pocos videos.

3.6. Preguntas adicionales

- ¿Cuántos comentarios recibieron reacciones visibles? 53.4 % tiene al menos un me gusta y 7.4 % tiene al menos una respuesta.
- ¿La mayoría de autores participa repetidamente? No: 9 de 332 autores (2.7 %) comenta en mas de un video observado.
- ¿El origen de recolección dominante es el mismo para videos y comentarios? En videos domina 'topic', mientras en comentarios domina 'channel'. Esto confirma que ambos archivos tienen coberturas distintas.

4. Red bipartita autor-video

4.1 y 4.2. Definición y construcción

La red es no dirigida y bipartita. Un conjunto de nodos contiene `author_channel_id` y el otro `video_id`. Se creó una arista por cada par autor-video observado. El peso es la cantidad de comentarios principales que ese autor publicó en ese video. `reply_count` no crea aristas porque no identifica a quienes respondieron.

metrica	valor
Autores	332.000
Videos	19.000
Nodos totales	351.000
Aristas autor-video	343.000
Peso total (comentarios)	406.000
Densidad bipartita	0.054
Componentes conexos preliminares	10.000
Nodos en componente mayor	286.000

4.3. Tablas entregadas

`red_bipartita_nodos.csv` contiene `node_id`, `tipo` y atributos descriptivos. `red_bipartita_aristas.csv` contiene `source`, `target`, `peso_comentarios`, `me_gusta` y respuestas agregadas. Los prefijos `autor::` y `video::` evitan colisiones entre identificadores de distinto tipo.




Figura 8. Red bipartita completa. No se eliminaron nodos ni aristas por razones estéticas; solo se limitaron las etiquetas para mantener legibilidad.

4.4 y 4.5. Lectura correcta de la red

La red contiene 10 componentes conexos observados. Los colores muestran componentes, no comunidades detectadas estadísticamente. 9 autores conectan al menos dos videos y son candidatos a estudiar como participantes recurrentes. Una conexión solo afirma co-participación de un autor en un video. No permite saber si leyo otros comentarios, respondió a otro usuario, estuvo de acuerdo, conoce al canal o mantiene una relación social fuera de YouTube.

Conclusiones del avance

- La integración es completa para el archivo entregado: 406 de 406 comentarios encuentran su video mediante video_id.
- Los identificadores son consistentes, pero las variables de tiempo relativo, los conteos textuales y las variables constantes requieren tratamiento explícito.
- La participación observada está concentrada: cinco videos acumulan 75.4 % de los comentarios.
- Las visualizaciones públicas y los comentarios recolectados describen dimensiones distintas y no deben interpretarse como equivalentes ni como causalidad.
- La red bipartita documenta 343 relaciones autor-video distintas y conserva todas las estructuras observadas.
- Los resultados describen exclusivamente la muestra recolectada. No se generalizan a todos los usuarios de YouTube ni a toda la población de Guatemala.

Reproducibilidad

El proyecto incluye datos, código, dependencias, tablas y figuras. Desde la carpeta raíz, cree el entorno, instale requirements.txt y ejecute python run.py. La ejecución sobrescribe los resultados con versiones reconstruidas a partir de los CSV. El README contiene instrucciones para Windows, macOS y Linux.